

Lista de Exercícios

Fundamentos de Estatística para Data Science

1. Estatística Descritiva · 2. Probabilidade e as 7 Distribuições Essenciais · 3. Fundamentos de Inferência · 4. Os 9 Testes Estatísticos Críticos
5. Métodos de Reamostragem · 6. Design Experimental e A/B Testing · 7. Estatística Bayesiana
8. Análise Multivariada · 9. Regressão e Modelagem · 10. Séries Temporais
-

1. Estatística Descritiva

Questão 1. Considere o conjunto de salários mensais (em R\$) de uma equipe de engenharia de dados:

4500, 5200, 5800, 6100, 6100, 7300, 7800, 8200, 9500, 24000

- a) Calcule a média, mediana e moda. O que a diferença entre média e mediana revela sobre a distribuição?
- b) Calcule o desvio padrão e a amplitude interquartil (IQR). Identifique outliers pelo critério $[Q_1 - 1,5 \cdot \text{IQR}, Q_3 + 1,5 \cdot \text{IQR}]$. Qual medida de dispersão é mais robusta nesse caso, e por quê?

Questão 2. Um dataset de avaliações de produtos possui distribuição assimétrica à direita com coeficiente de curtose de 4,8.

- a) Explique o que significa assimetria positiva e o que curtose > 3 indica sobre as caudas da distribuição.
- b) Um analista decide usar a média para representar o “valor típico”. Critique essa escolha e sugira uma alternativa mais adequada, justificando estatisticamente.
- c) Construa uma tabela de frequência com 5 classes para os dados de salário da Questão 1. A partir dela, estime graficamente onde se localiza moda, mediana e média, e justifique a posição relativa entre elas.

Questão 3. Dois grupos de profissionais foram avaliados quanto ao número de horas semanais de estudo. Grupo A (desenvolvedores): média 8h, desvio padrão 1,5h. Grupo B (cientistas de dados): média 12h, desvio padrão 4h.

- a) Calcule o coeficiente de variação (CV) de cada grupo. Qual grupo é mais homogêneo em relação à sua própria média?
- b) Explique por que o CV é preferível ao desvio padrão isolado para comparar dispersão entre grupos com médias diferentes.

Questão 4. Um pipeline de dados extrai registros de vendas diárias ao longo de 30 dias. Os valores de receita diária (R\$ mil) apresentam assimetria +1,8 e curtose 6,2.

- a) Como essas medidas de forma indicam que a distribuição se afasta da normalidade? Descreva o formato esperado do histograma.

- b) Ao reportar a receita “típica” diária para um stakeholder, você escolheria média ou mediana? Justifique e descreva como apresentaria também uma medida de dispersão adequada.

2. Probabilidade e as 7 Distribuições Essenciais

▷ Fundamentos de Probabilidade

Questão 5. Um filtro de spam classifica e-mails como *spam* ou *não spam*. Sabe-se que 20% dos e-mails são spam, a sensibilidade do filtro é 95% e a especificidade é 90%.

- Um e-mail foi classificado como spam. Qual a probabilidade de ele realmente ser spam? (Use o Teorema de Bayes.)
- O Teorema do Limite Central garante que a soma de variáveis independentes converge para uma normal. Explique por que isso é relevante para classificadores probabilísticos em larga escala.
- Se o volume de e-mails recebidos dobrar, como isso afeta a precisão do filtro? Use o conceito de prevalência para justificar.

Questão 6. Em um sistema distribuído, os jobs de extração de dados falham esporadicamente com taxa média de 2 por dia.

- Usando a distribuição de Poisson, calcule a probabilidade de zero falhas em um dia e de mais de 4 falhas.
- O tempo até a próxima falha segue uma distribuição Exponencial com a mesma taxa $\lambda = 2$. Qual é o tempo médio esperado até a próxima falha? Calcule $P(T > 1 \text{ h})$ para T em horas, com $\lambda = 1/12$ falhas por hora.

▷ Distribuição Normal (Gaussiana)

Questão 7. Um filtro de Kalman modela o ruído de sensor de temperatura como $\varepsilon \sim \mathcal{N}(0, \sigma^2)$. Medições reais apresentaram resíduos com média $\hat{\mu} = 0,3^\circ\text{C}$ e desvio padrão $\hat{\sigma} = 1,2^\circ\text{C}$.

- Calcule a probabilidade de um resíduo individual exceder 2°C em módulo. Use a distribuição normal e a tabela z .
- Teste formalmente se a premissa de média zero é sustentada, com $\alpha = 0,05$ e $n = 100$ observações. O filtro está calibrado?

Questão 8. Um algoritmo de identificação de assinaturas de áudio assume amplitudes de ruído branco com distribuição Normal. Ao analisar 500 amostras, um engenheiro detecta curtose 5,1 e assimetria 0,8.

- Aplique o teste de Shapiro-Wilk (descreva seu funcionamento) para verificar a premissa de normalidade. O que a curtose elevada sugere sobre a distribuição real?
- Se a normalidade for rejeitada, quais ajustes seriam necessários? Cite uma alternativa paramétrica e uma não-paramétrica.

▷ Distribuição Uniforme

Questão 9. Um agente de aprendizado por reforço utiliza política ϵ -greedy para explorar um espaço de ações em ambiente de simulação de arranjos de antenas. Em cada passo, com probabilidade $\epsilon = 0,1$, uma ação é amostrada uniformemente entre 8 possíveis.

- a) Calcule a probabilidade de a ação ótima ser selecionada em um passo de exploração. Como essa probabilidade muda se o número de ações dobrar?
- b) Em 1.000 passos de treinamento, quantas vezes espera-se que o agente explore em média? Modele como Binomial e calcule o desvio padrão desse número.

Questão 10. Um gerador de números pseudo-aleatórios inicializa pesos de uma rede neural amostrados de $U(-0,5, 0,5)$.

- a) Calcule a média, variância e desvio padrão dessa distribuição. Por que inicialização com variância controlada é importante para o treinamento?
- b) Se 1.000 pesos forem amostrados, qual a probabilidade de a média amostral desviar mais de 0,02 da média verdadeira? Use o Teorema do Limite Central.

▷ Distribuição Bernoulli / Binomial

Questão 11. Um pipeline de dados insere registros em uma tabela PostgreSQL com restrição de unicidade (`cod_ativo` não duplicado em `mv_debentures`). Sabe-se que 3% das tentativas falham por violação de chave.

- a) Modele o número de falhas em um lote de 200 inserções como Binomial. Calcule a probabilidade de zero falhas e de mais de 10 falhas.
- b) Calcule a *binary cross-entropy* para um classificador que prediz probabilidade 0,7 para $y = 1$ e 0,3 para $y = 0$. Qual a relação com a log-verossimilhança da Bernoulli?

Questão 12. Um modelo de classificação binária é avaliado em 500 exemplos. A taxa de acerto sob hipótese nula (chute aleatório) é 50%.

- a) O modelo acertou 285 exemplos. Usando a aproximação Normal à Binomial, teste se o modelo é significativamente melhor que o acaso ($\alpha = 0,05$).
- b) Calcule o número mínimo de acertos necessários para rejeitar H_0 ao nível de 5%. Como isso se relaciona com o conceito de poder estatístico?

▷ Distribuição de Poisson

Questão 13. Um serviço AWS Lambda é invocado em média 45 vezes por minuto durante rotinas de extração. O sistema entra em erro se receber mais de 60 invocações por minuto.

- a) Calcule a probabilidade de sobrecarga em um minuto qualquer usando a distribuição de Poisson.
- b) Se as invocações seguem um processo de Poisson, o tempo entre invocações sucessivas segue qual distribuição? Qual é o tempo médio entre invocações?

Questão 14. Um engenheiro de dados monitora jobs de ETL em um cluster ECS. Historicamente, ocorrem 3 falhas por hora em média.

- a) Calcule a probabilidade de ocorrerem exatamente 0, 1 e 2 falhas em uma hora. Descreva a forma da PMF para $\lambda = 3$.

- b) Em 8 horas de operação, qual a probabilidade de ocorrerem mais de 30 falhas no total? Use a aproximação Normal à Poisson e justifique quando ela é válida.

▷ Distribuição Exponencial

Questão 15. A latência de resposta de uma API de dados financeiros segue uma distribuição Exponencial com média de 200ms ($\lambda = 1/200$).

- a) Calcule a probabilidade de uma requisição ser respondida em menos de 100ms. E de demorar mais de 500ms.
- b) Explique a propriedade de ausência de memória da distribuição Exponencial. O que ela implica na prática para monitoramento de SLAs?

Questão 16. O tempo até a falha de um job de extração em lote segue distribuição Exponencial com taxa $\lambda = 0,05$ falhas/hora.

- a) Calcule o MTTF (*Mean Time To Failure*) e a probabilidade de o job rodar mais de 30 horas sem falhar.
- b) Um SRE precisa garantir 99% de disponibilidade. Qual deve ser o intervalo máximo entre *health checks* automáticos? Formalize usando a CDF da Exponencial.

▷ Distribuição Beta

Questão 17. Antes de um experimento A/B, a equipe acredita que a taxa de conversão θ está entre 5% e 15%, com maior massa em torno de 10%, representado por $\theta \sim \text{Beta}(5, 45)$.

- a) Calcule a média e variância dessa distribuição. Após observar 30 conversões em 200 visitas, qual é a posteriori e sua nova média?
- b) Compare a influência da priori com $n = 200$ e $n = 2000$ (mesma proporção de conversões). O que acontece com a posteriori à medida que os dados crescem?

Questão 18. Um sistema dinâmico de recomendação atualiza a confiança em cada item usando uma distribuição Beta. Item A começa com $\text{Beta}(1, 1)$ (priori não informativa). Após 10 interações positivas e 5 negativas:

- a) Calcule a posteriori e determine o intervalo de credibilidade de 90% para a probabilidade de aceitação do item.
- b) Dois itens têm posteriori $\text{Beta}(12, 6)$ e $\text{Beta}(60, 30)$. Ambos têm a mesma média. Qual você recomendaria com maior confiança e por quê?

▷ Distribuição Log-Normal

Questão 19. Volumes de crédito concedido em uma carteira seguem distribuição Log-Normal com $\mu = 10,5$ e $\sigma = 0,8$ (escala logarítmica).

- a) Calcule a mediana e a média na escala original (R\$). Por que a mediana é geralmente preferida para reportar o “valor típico” de crédito?
- b) Um regulador exige que no máximo 5% dos contratos excedam R\$ 100.000. Verifique se esse limite é respeitado calculando $P(X > 100.000)$.

Questão 20. Um analista ajusta uma distribuição Log-Normal a dados de precificação de ativos e obtém bom ajuste (p -valor K-S = 0,23). Um colega sugere usar a Normal

diretamente na escala original.

- a) Quais são as implicações práticas de usar Normal em vez de Log-Normal para modelar preços de ativos? Cite pelo menos dois problemas concretos.
- b) Como o teste de Kolmogorov-Smirnov avalia a qualidade do ajuste? O que significa o p -valor de 0,23 nesse contexto?

3. Fundamentos de Inferência

Questão 21. Deseja-se comparar o desempenho médio (nota 0–10) de alunos de duas escolas. Escola A: $n = 35$, $\bar{x}_A = 6,8$, $s_A = 1,4$. Escola B: $n = 40$, $\bar{x}_B = 7,3$, $s_B = 1,6$.

- a) Formule as hipóteses e realize um teste t bicaudal com $\alpha = 0,05$. Há diferença significativa?
- b) Explique a diferença entre erro Tipo I e Tipo II nesse contexto. Como $\alpha = 0,01$ afetaria o poder do teste?
- c) Calcule o intervalo de confiança de 95% para a diferença $\mu_A - \mu_B$ e interprete.

Questão 22. Em um estudo sobre preferência de interface, 200 usuários foram distribuídos em quatro grupos (A, B, C e D). As frequências de aprovação foram: 62, 48, 55 e 35.

- a) Aplique um teste χ^2 de aderência com $\alpha = 0,05$. Calcule a estatística e o grau de liberdade.
- b) O p -valor foi 0,031. Interprete em linguagem acessível para um stakeholder não-técnico, sem usar o termo “ p -valor”.
- c) Quais premissas do χ^2 precisam ser verificadas? O que fazer se uma célula tiver frequência esperada menor que 5?

Questão 23. Um pesquisador testa se um novo algoritmo de recomendação reduz o tempo de resposta. Coleta 25 pares de medições (antes e depois) e obtém diferença média de -12ms com desvio padrão das diferenças de 20ms .

- a) Que tipo de teste t deve ser aplicado? Formule as hipóteses e calcule a estatística de teste.
- b) O p -valor foi 0,007. O pesquisador afirma que “a probabilidade de o algoritmo não funcionar é 0,7%”. Corrija essa interpretação.

Questão 24. Três arquiteturas de agentes LangGraph foram testadas em tempo de execução (ms) em 30 execuções cada. Os dados violam a premissa de normalidade (assimetria severa).

- a) Por que o uso de ANOVA seria inadequado nesse cenário? Qual alternativa não-paramétrica deve ser usada?
- b) Descreva os passos do teste de Kruskal-Wallis e explique o que significa rejeitar H_0 nesse contexto.
- c) Se há diferença entre grupos, como identificar *quais* pares diferem? Descreva o procedimento de comparações múltiplas adequado.

4. Os 9 Testes Estatísticos Críticos

▷ Categoria A: Comparação de Médias e Benchmarking

Teste T de Student

Questão 25. Dois modelos de machine learning foram avaliados em 30 rodadas cada. Modelo Base: $\bar{x} = 0,823$, $s = 0,018$. Modelo Candidato: $\bar{x} = 0,841$, $s = 0,021$.

- Realize um teste t de duas amostras independentes com $\alpha = 0,05$. O modelo candidato é significativamente melhor?
- Calcule o *effect size* (Cohen's d). Como interpretar $d = 0,2$ versus $d = 0,8$ em termos práticos para decisão de implantação?

Questão 26. Uma equipe mede a latência (ms) de um serviço antes e depois de uma otimização em 20 endpoints idênticos. Diferença média = -35ms , desvio padrão das diferenças = 18ms .

- Que variante do teste t deve ser usada? Calcule a estatística e conclua com $\alpha = 0,05$.
- Antes do teste, o engenheiro deve verificar a normalidade das diferenças. Descreva os passos do Shapiro-Wilk e discuta o que fazer se a normalidade for rejeitada.

U de Mann-Whitney (Wilcoxon)

Questão 27. Dois pipelines de dados são comparados em tempo de execução. O Pipeline A apresenta distribuição fortemente assimétrica devido a gargalos aleatórios. Amostras de tamanho 25 foram coletadas de cada.

- Por que o teste t seria inadequado? Descreva os passos do teste U de Mann-Whitney e explique o que a estatística U mede.
- O p -valor foi 0,03. Interprete o resultado. O que significa dizer que o teste compara a probabilidade de uma observação do grupo A superar uma do grupo B?

Questão 28. Um analista quer comparar a satisfação de clientes (escala Likert 1–5) entre duas regiões. Região Norte: $n = 40$, mediana = 3. Região Sul: $n = 38$, mediana = 4.

- Por que dados em escala Likert não devem ser analisados com teste t ? O Mann-Whitney seria mais adequado?
- O teste retornou $p = 0,08$ com $\alpha = 0,05$. Um gestor insiste que “quase significativo” justifica ação. Critique essa postura.

ANOVA

Questão 29. Quatro arquiteturas de agentes LangGraph foram testadas em tempo de execução (ms): 50 execuções cada. Médias: 210, 185, 230 e 195ms, com variâncias similares.

- Enuncie as hipóteses da ANOVA de um fator. Quais são as três premissas que devem ser verificadas antes de aplicá-la?
- A ANOVA retornou $F = 4,82$, $p = 0,003$. O que isso indica? Por que não se pode concluir diretamente qual arquitetura é melhor?

Questão 30. Após rejeitar H_0 na ANOVA acima, o analista realiza comparações múltiplas entre os 4 grupos.

- a) Explique por que realizar todas as comparações pareadas com testes t individuais é inadequado. Quantas comparações seriam necessárias?
- b) Descreva o teste de Tukey HSD como alternativa. Em que sentido ele controla o erro familiar (*familywise error rate*)?

Kruskal-Wallis

Questão 31. Três serviços de API são comparados em latência (ms). Os dados apresentam outliers extremos e violam normalidade. Amostras: $n_1 = 30$, $n_2 = 28$, $n_3 = 32$.

- a) Descreva o procedimento do teste de Kruskal-Wallis (ranking global, estatística H). Quais são suas hipóteses?
- b) O teste retornou $p = 0,01$. Como identificar quais pares de serviços diferem significativamente? Descreva o pós-teste adequado.

Questão 32. Um engenheiro compara o consumo de memória (GB) de quatro versões de um sistema de ingestão de dados. Os dados são fortemente assimétricos.

- a) Compare ANOVA e Kruskal-Wallis em termos de potência estatística quando a normalidade é violada. Quando Kruskal-Wallis perde potência em relação à ANOVA?
- b) O teste não rejeita H_0 ($p = 0,12$). Um gerente conclui que “todas as versões são iguais”. Corrija essa interpretação.

▷ Categoria B: Variância e Estabilidade

Teste F de Fisher-Snedecor

Questão 33. Dois modelos preditivos de inadimplência são comparados. Modelo X: 50 previsões com $s_X^2 = 0,042$. Modelo Y: 50 previsões com $s_Y^2 = 0,018$.

- a) Realize o teste F de igualdade de variâncias com $\alpha = 0,05$. O Modelo Y é significativamente mais estável?
- b) Em um contexto de negócio, por que um modelo com menor variância (mesmo sem maior acurácia média) pode ser preferível? Dê um exemplo concreto.

Questão 34. Um sistema de previsão de demanda é comparado com um baseline. Ambos têm RMSE similar, mas o sistema novo apresenta $s^2 = 15,3$ contra $s^2 = 38,7$ do baseline ($n = 40$ cada).

- a) Aplique o teste F a $\alpha = 0,01$. Qual é o grau de liberdade do numerador e do denominador?
- b) Quais premissas o teste F assume? O que fazer se os dados forem fortemente não-normais?

▷ Categoria C: Dados Categóricos e Falhas

Qui-Quadrado (χ^2)

Questão 35. Um dataset de relatórios de rating contém variáveis categóricas: setor da empresa (5 categorias) e nota de crédito (4 categorias). O objetivo é verificar se as duas variáveis são associadas.

- a) Formule H_0 e H_1 . Calcule os graus de liberdade para o teste χ^2 de independência.
- b) A estatística $\chi^2 = 28,4$ com $p < 0,001$. Além de rejeitar H_0 , como quantificar a força da associação? Descreva o coeficiente V de Cramér.

Questão 36. Em *feature selection* para um modelo de crédito, um analista aplica o teste χ^2 em 20 variáveis categóricas e seleciona 7 com $\alpha = 0,05$.

- a) Qual o risco de realizar 20 testes simultâneos sem correção? Calcule o número esperado de falsos positivos.
- b) Aplique a correção de Bonferroni e discuta se ela é adequada ou se FDR (Benjamini-Hochberg) seria mais apropriado nesse contexto.

Teste Exato de Fisher

Questão 37. Um parser de PDFs falha ao processar layouts específicos da CVM. Em 200 documentos testados: 180 com layout padrão (3 falhas) e 20 com layout especial (4 falhas).

- a) Monte a tabela de contingência 2×2 e explique por que o teste χ^2 seria inapropriado aqui. Por que o Teste Exato de Fisher é preferível?
- b) O teste retornou $p = 0,004$. Interprete: a taxa de falha está associada ao tipo de layout? Que ação prática isso sugere para o pipeline de extração?

Questão 38. Em um experimento de usabilidade com 30 participantes, 15 testaram o protótipo A e 15 o protótipo B. Completaram a tarefa: 12 do grupo A e 7 do grupo B.

- a) Por que o Teste Exato de Fisher é mais adequado que o χ^2 com amostras tão pequenas? Calcule a probabilidade exata usando a distribuição hipergeométrica.
- b) O resultado foi marginalmente significativo ($p = 0,049$). Um designer quer concluir que “A é definitivamente melhor”. Que *caveats* estatísticos você levantaria?

▷ Categoria D: Aderência de Distribuição

Kolmogorov-Smirnov (K-S)

Questão 39. Um modelo de crédito foi treinado com dados de 2020–2022. Em 2024, as distribuições de renda e idade dos solicitantes parecem ter mudado. O teste K-S é aplicado para detectar *data drift*.

- a) Descreva como o teste K-S compara duas distribuições. O que a estatística D representa geometricamente?
- b) O teste retornou $D = 0,21$ e $p = 0,003$ para a variável renda. Interprete: há evidência de drift? Que ações de MLOps deveriam ser disparadas?

Questão 40. Um engenheiro compara a distribuição de latências em produção com a registrada nos testes de carga (referência). Ambas as amostras têm $n = 500$.

- a) Qual variante do teste K-S é aplicada aqui (uma amostra vs. referência teórica, ou duas amostras)? Explique a diferença.
- b) O teste não rejeita H_0 ($p = 0,18$). Isso prova que as distribuições são iguais? Discuta as limitações do K-S em amostras grandes e pequenas.

Shapiro-Wilk

Questão 41. Antes de aplicar um teste t para comparar latências de dois servidores, um engenheiro testa a normalidade de cada amostra ($n = 25$ cada) com Shapiro-Wilk.

- a) O teste retornou $p = 0,04$ para o Servidor A e $p = 0,31$ para o Servidor B. Quais são as implicações para o teste t ? Existe uma alternativa robusta?
- b) Por que o Shapiro-Wilk é preferível ao K-S para testar normalidade em amostras pequenas ($n < 50$)?

Questão 42. Um time de dados aplica Shapiro-Wilk a 15 variáveis numéricas antes de rodar uma ANOVA multivariada. Três variáveis rejeitam normalidade a $\alpha = 0,05$.

- a) Discuta o problema de realizar 15 testes de normalidade simultâneos. Qual a probabilidade de ao menos uma rejeição espúria?
- b) Para as variáveis que violam normalidade, descreva duas transformações possíveis (e.g., log, Box-Cox) e quando cada uma é indicada.

5. Métodos de Reamostragem

Questão 43. Um dataset com 60 observações é usado para estimar a mediana da renda (R\$3.800).

- a) Descreva o procedimento Bootstrap para construir um IC de 95% para a mediana. Por que é preferível à abordagem analítica?
- b) Com 10.000 reamostras, a distribuição das medianas teve média R\$3.812 e desvio padrão R\$210. Construa o IC pelo método do percentil e interprete.
- c) Explique a diferença entre Bootstrap paramétrico e não-paramétrico. Quando cada abordagem é indicada?

Questão 44. Um modelo de regressão foi avaliado com validação cruzada 5-fold, resultando nos RMSE: 12,3 — 11,8 — 13,1 — 12,0 — 12,6.

- a) Calcule o RMSE médio e o desvio padrão entre folds. Por que a variância entre folds é informação importante?
- b) Qual a diferença entre k -fold e holdout simples (70/30)? Quando LOO seria mais indicado?
- c) Em que situação um teste de permutação seria preferível a um teste t para comparar dois modelos? Descreva o procedimento.

Questão 45. Uma empresa quer comparar a acurácia de dois modelos (A e B) em 200 exemplos. Modelo A: 142 acertos. Modelo B: 156 acertos.

- a) Descreva como usar um teste de permutação para verificar se a diferença de acurácia é estatisticamente significativa.
- b) Qual é a vantagem do teste de permutação em relação ao teste z de proporções nesse contexto?

Questão 46. Um cientista de dados aplica Bootstrap para estimar o coeficiente de correlação de Pearson entre duas variáveis financeiras, obtendo $\hat{r} = 0,62$ na amostra original.

- a) Com 5.000 reamostras Bootstrap, o histograma das correlações amostrais apresentou

assimetria moderada. Qual método de IC (percentil, básico ou BCa) seria mais apropriado e por quê?

- b) O IC de 95% obtido foi $[0,41; 0,78]$. Pode-se afirmar que a correlação populacional é positiva com 95% de confiança? Justifique.

6. Design Experimental e A/B Testing

Questão 47. Uma empresa quer testar se um novo botão (vermelho vs. azul) aumenta a CTR de 5% para 6%, com poder de 80% e $\alpha = 0,05$.

- Calcule o tamanho amostral necessário por grupo. Como α , poder e efeito mínimo detectável se relacionam?
- Após o teste, p -valor = 0,047. Um analista conclui imediatamente que o vermelho é melhor. Aponte dois problemas metodológicos nessa conclusão.
- Defina o *peeking problem* em A/B testing e descreva como o Sequential Testing (SPRT) mitiga esse risco.

Questão 48. Uma equipe testa simultaneamente três versões de e-mail marketing (A, B e C), medindo taxa de abertura.

- Por que três testes t independentes sem correção elevam a taxa de falsos positivos? Calcule a probabilidade de ao menos um falso positivo para $\alpha = 0,05$.
- Descreva a correção de Bonferroni e compare com Benjamini-Hochberg (FDR). Em qual cenário cada um é mais indicado?
- Se a versão B ganhar com diferença de 0,3 p.p., a empresa deveria implementá-la? Discuta o trade-off entre significância estatística e efeito mínimo relevante para o negócio.

Questão 49. Em um experimento de plataforma, usuários são randomizados entre dois grupos. O grupo tratado apresenta conversão 12% maior, mas 8% dos usuários “vazaram” entre grupos (*network effect*).

- O que é *SUTVA* (Stable Unit Treatment Value Assumption) e por que o vazamento viola essa premissa?
- Descreva duas estratégias para lidar com interferência entre unidades (e.g., *cluster randomization*).

Questão 50. Um analista obtém $n = 2.000$ por grupo como tamanho amostral necessário. O experimento é encerrado após 5 dias com apenas 800 usuários por grupo porque o p -valor atingiu 0,03.

- Explique por que encerrar o teste antecipadamente com base no p -valor viola as premissas do teste de hipótese clássico.
- Como o poder estatístico do teste se compara ao planejado, dado o tamanho amostral menor? O que isso implica sobre a confiabilidade do resultado?

7. Estatística Bayesiana

Questão 51. Uma equipe quer estimar a taxa de conversão θ de uma landing page. A priori é $\theta \sim \text{Beta}(5, 15)$. Em uma semana, observam 40 conversões em 200 visitas.

- Determine a distribuição posteriori. Qual é a estimativa pontual bayesiana (média posteriori)?
- Compare o intervalo de credibilidade de 95% com o intervalo de confiança frequentista. Qual é a diferença fundamental na interpretação?
- Se na semana seguinte forem observadas 15 conversões em 80 visitas, como a posteriori anterior torna-se a nova priori? Calcule a posteriori final.

Questão 52. Um pesquisador afirma que “a probabilidade de a hipótese nula ser verdadeira é 3%”, com base em p -valor = 0,03.

- Explique por que essa interpretação está errada. O que o p -valor realmente mede?
- Como o Fator de Bayes oferece uma alternativa mais intuitiva para quantificar evidência a favor ou contra uma hipótese?

Questão 53. Em um sistema de monitoramento de crédito, a probabilidade inicial (*priori*) de inadimplência é 5%. Um modelo de *scoring* classifica um cliente como “alto risco” com probabilidade 85% dado inadimplência real, e com probabilidade 10% dado adimplência.

- Calcule a probabilidade posteriori de inadimplência dado que o modelo classificou o cliente como “alto risco”.
- Um segundo sinal independente (atraso em outra instituição) também indica risco. Como a atualização bayesiana sequencial incorpora essa nova evidência? Calcule a posteriori final.

Questão 54. Uma priori $\text{Beta}(2, 8)$ reflete a crença de que a CTR de um anúncio é baixa. Após exibir o anúncio 500 vezes e observar 60 cliques:

- Calcule a posteriori e compare a média posteriori com a proporção amostral bruta (60/500). Por que diferem?
- O que acontece com a influência da priori à medida que as observações crescem? Ilustre comparando $n = 500$ vs. $n = 50$ (mesma proporção de cliques).

8. Análise Multivariada

Questão 55. Uma matriz de correlação entre variáveis de saúde (IMC, pressão sistólica, colesterol, horas de exercício) revelou:

$$R = \begin{pmatrix} 1,00 & 0,68 & 0,61 & -0,54 \\ 0,68 & 1,00 & 0,72 & -0,41 \\ 0,61 & 0,72 & 1,00 & -0,38 \\ -0,54 & -0,41 & -0,38 & 1,00 \end{pmatrix}$$

- Identifique o par com maior correlação. A correlação negativa entre exercício e IMC implica causalidade? Dê um exemplo de variável de confundimento.
- Calcule a correlação de Spearman para o par (IMC, pressão) se os dados apresentam outliers severos. Por que Spearman pode ser mais adequado que Pearson nesse caso?

- c) Uma PCA sobre essas 4 variáveis explicou 82% da variância com 2 componentes. O que isso significa e quando faz sentido reduzir dimensionalidade?

Questão 56. Em um projeto de segmentação de clientes, aplicou-se k-means com $k = 4$ sobre 10 variáveis comportamentais padronizadas.

- Por que é necessário padronizar as variáveis antes do k-means? O que acontece se uma variável tiver escala muito maior que as demais?
- Descreva o método do cotovelo (*elbow method*) e o índice de silhueta para escolha de k . Qual deles é mais interpretável do ponto de vista de negócio?
- Como você validaria que os clusters encontrados são estatisticamente estáveis e não um artefato do algoritmo?

Questão 57. Um dataset de análise de risco de crédito possui 50 variáveis. Uma PCA mostra que os 5 primeiros componentes explicam 88% da variância total.

- Explique o que são os *loadings* em PCA. Como interpretar que uma variável tem loading alto no primeiro componente principal?
- O analista decide treinar regressão logística sobre os 5 componentes em vez das 50 variáveis originais. Quais são as vantagens e desvantagens dessa abordagem?

Questão 58. Duas variáveis financeiras, volume de crédito e spread de juros, apresentam correlação de Pearson $r = 0,15$ ($p < 0,001$, $n = 50.000$).

- A correlação é estatisticamente significativa. Isso significa que é praticamente relevante? Discuta a diferença entre significância estatística e relevância prática em amostras grandes.
- Calcule o R^2 correspondente e interprete o que ele diz sobre a relação entre as variáveis.

9. Regressão e Modelagem

Questão 59. Um modelo de regressão linear múltipla foi ajustado para prever preço de imóveis (R\$ mil) com área x_1 (m²), quartos x_2 e distância ao centro x_3 (km):

$$\hat{y} = 80 + 3,2x_1 + 15x_2 - 4,5x_3 \quad (R^2 = 0,76, R^2_{\text{adj}} = 0,74)$$

- Interprete os coeficientes de x_1 e x_3 . O que o R^2_{adj} indica?
- O VIF de x_1 é 8,4 e de x_2 é 7,9. O que isso sugere? Como Ridge Regression mitigaria esse problema?
- Um novo imóvel tem 90m², 3 quartos e está a 5km do centro. Forneça a previsão pontual e discuta uma limitação do modelo ao extrapolar.

Questão 60. Um modelo de regressão logística foi treinado para prever churn. Matriz de confusão ($n = 500$):

	Previsto: Churn	Previsto: Não Churn
Real: Churn	80	20
Real: Não Churn	30	370

- Calcule precisão, recall, F1-score e acurácia. Qual métrica é mais relevante se o custo de não identificar um churn for muito alto?

- b) Explique como o threshold afeta o trade-off entre precisão e recall. O que a curva ROC representa?
- c) O coeficiente da variável “dias_sem_login” foi 0,8 no modelo logístico. Calcule e interprete o odds ratio correspondente.

Questão 61. Ao ajustar regressão linear simples para prever latência de API em função do volume de requisições, o gráfico de resíduos versus valores ajustados apresenta um padrão de funil (variância crescente).

- a) Que premissa do modelo está sendo violada? Como isso afeta as inferências?
- b) Sugira duas abordagens para corrigir o problema e descreva brevemente como cada uma funciona.

Questão 62. Dois modelos foram ajustados ao mesmo dataset de precificação de crédito: um Lasso e um Ridge. O Lasso zerou 8 dos 15 coeficientes; o Ridge encolheu todos.

- a) Explique a diferença matemática entre as penalizações L1 (Lasso) e L2 (Ridge). Por que o Lasso promove esparsidade?
- b) Em que cenário você preferiria Lasso? Em que cenário Ridge seria mais adequado? Relacione com o conceito de multicolinearidade.

10. Séries Temporais

Questão 63. Uma série temporal de vendas mensais apresenta tendência crescente, sazonalidade anual e resíduos com autocorrelação no lag 1.

- a) Descreva a decomposição STL e o que cada componente representa. Como você testaria formalmente a estacionariedade?
- b) O teste ADF retornou p -valor = 0,32. O que isso indica? Que transformação aplicaria antes de ajustar um ARIMA?
- c) Descreva a diferença entre decomposição aditiva e multiplicativa. Em que tipo de série a multiplicativa é mais adequada?

Questão 64. Um modelo ARIMA(1,1,1) foi ajustado a dados de temperatura mensal. Os resíduos apresentaram ACF e PACF sem picos significativos e Ljung-Box com p -valor = 0,41.

- a) Interprete o diagnóstico: o modelo está bem especificado? Explique o que $(p, d, q) = (1, 1, 1)$ significa.
- b) Cite duas limitações do ARIMA com sazonalidade forte. Que extensão do modelo seria usada e quais parâmetros adicionais ela introduz?
- c) Compare o que os gráficos ACF e PACF de um AR(1) e de um MA(1) puros apresentariam. Como isso guia a escolha de p e q ?

Questão 65. Um analista de dados financeiros observa que a variância de retornos de ações aumenta durante períodos de crise (heterocedasticidade condicional).

- a) Por que o modelo ARIMA falha em capturar esse comportamento? O que é um modelo GARCH e qual problema ele resolve?
- b) O teste ARCH-LM retornou p -valor = 0,001. O que isso indica e qual seria o próximo passo na modelagem?

Questão 66. Dados de temperatura diária de uma cidade mostram sazonalidade semanal (fins de semana com padrão diferente) e anual.

- a) Como o modelo $\text{SARIMA}(p, d, q)(P, D, Q)_s$ estende o ARIMA para capturar sazonalidade? O que o parâmetro s representa nesse caso?
- b) Descreva como a validação de séries temporais difere do cross-validation padrão. Por que não se pode embaralhar os dados?

Bons estudos! — Lista gerada a partir do roteiro de Estatística para Data Science.